# Text mining

## 1. Введение в автоматическую обработку текстов

Дмитрий Ильвовский, Екатерина Черняк

dilvovsky@hse.ru, echernyak@hse.ru

Национальный Исследовательский Университет – Высшая Школа Экономики
НУЛ Интеллектуальных систем и структурного анализа

January 25, 2017

# Краткая история AOT (1)

- 7 января 1954. Джорджтаунский эксперимент по машинному переводу с русского на английский;
- 1957. Ноам Хомский ввел “универсальную грамматику”;
- 1961. Начинается сбор Брауновского корпуса;
- конец 1960-х. ELIZA — программа, ведущая психотерапевтические разговоры;
- 1975. Солтон ввел векторную модель (Vector Space Model, VSM);
- до 1980–х. Методы решения задач, основанные на правилах;
- после 1980–х. Методы решения задач, основанные на машинном обучении и корпусной лингвистике;
- 1998. Понте и Крофт вводят языковую модель (Language Model, LM);

# Краткая история АОТ (2)

- конец 1990–х. Вероятностные тематические модели (LSI, pLSI, LDA, и т.д.) ;
- 1999. Опубликован учебник Маннинга и Щютце “Основы статистической автоматической обработки текстов” (“Foundations of Statistical Natural Language Processing”) ;
- 2009. Опубликован учебник Берда, Кляйна и Лопера “Автоматическая обработка текстов на Python” (“Natural Language Processing with Python”) ;
- 2014. Deep learning in NLP. Mikolov, Tomas и др. “Efficient estimation of word representations in vector space”.

# Кривые развития АОТ (Э.Камбрия)

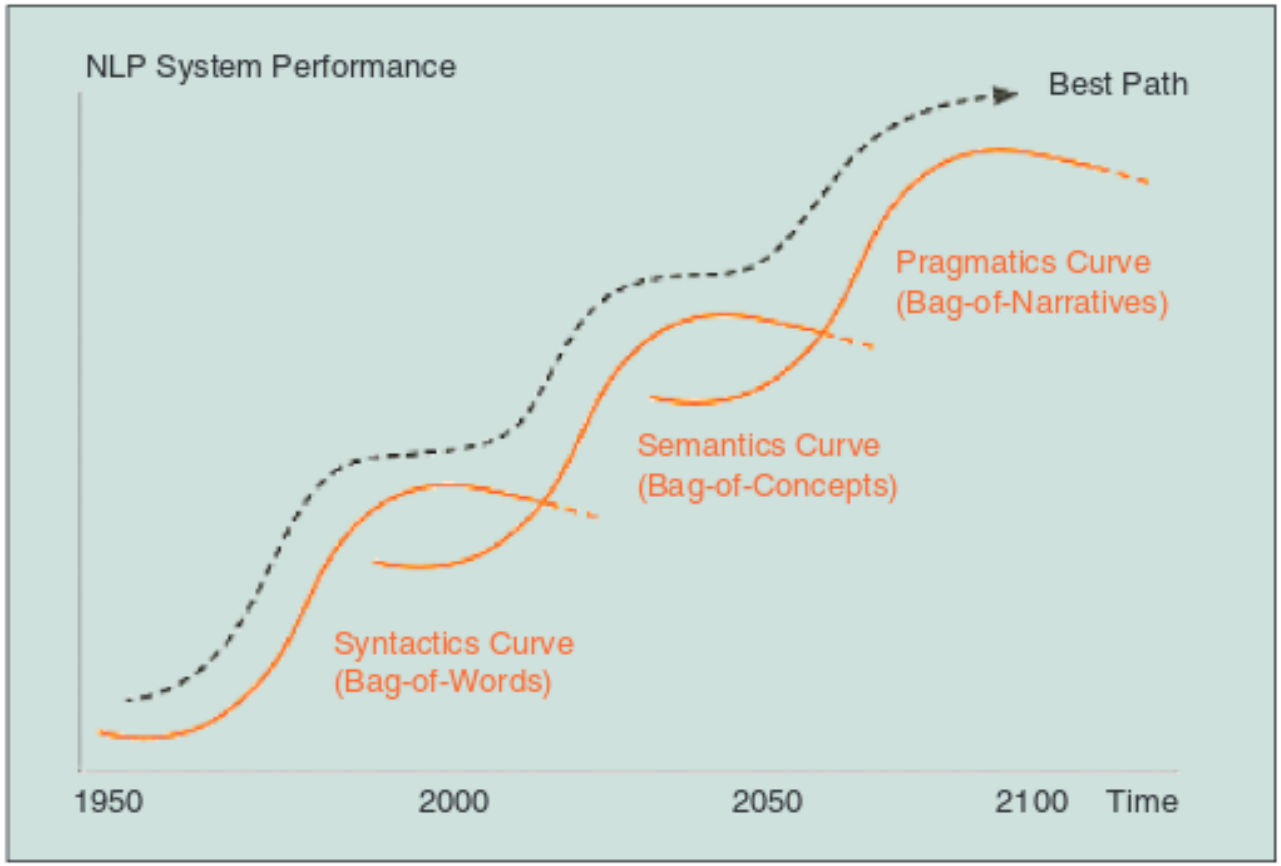

# Основные задачи АОТ

- Машинный перевод
- Классификация текстов
  - Фильтрация спама
  - По тональности
  - По теме или жанру
- Кластеризация текстов
- Извлечение информации
  - Фактов и событий
  - Именованных сущностей
- Вопросно-ответные системы
- Суммаризация текстов
- Генерация текстов
- Распознавание речи
- Проверка правописания
- Оптическое распознавание символов
- Пользовательские эксперименты и оценка точности и качества методов

# Основные техники

- Уровень символов:
  - Токенизация: разбиение текста на слова
  - Разбиение текста на предложения
- Уровень слов – морфология:
  - Разметка частей речи
  - Снятие морфологической неоднозначности
- Уровень предложений – синтаксис:
  - Выделенние именных или глагольных групп (chunking)
  - Выделенние семантических ролей
  - Деревья составляющих и зависимостей
- Уровень смысла – семантика и дискурс:
  - Разрешение кореферентных связей
  - Анализ дискурсивных связей
  - Выделение синонимов
  - Анализ аргументативных связей

# Основные подходы

1. Методы, основанные на правилах
2. Методы, основанные на статистическом анализе и машинном обучении
3. Комбинированные методы

# Основные проблемы

- Неоднозначность
  - Лексическая неоднозначность
    - ★ орган, парить, рожки, атлас
  - Морфологическая неоднозначность
    - ★ Хранение денег в банке.
    - ★ Что делают белки в клетке?
  - Синтаксическая неоднозначность
    - ★ Мужу изменять нельзя.
    - ★ Его удивил простой солдат.
- Неологизмы: печеньки, заинстаграммить, репостнуть, расшарить
- Разные варианты написания: Россия, Российская Федерация, РФ
- Нестандартное написание: каг дила?

# How many meanings can you get for the sentence “I saw the man on the hill with a telescope”?

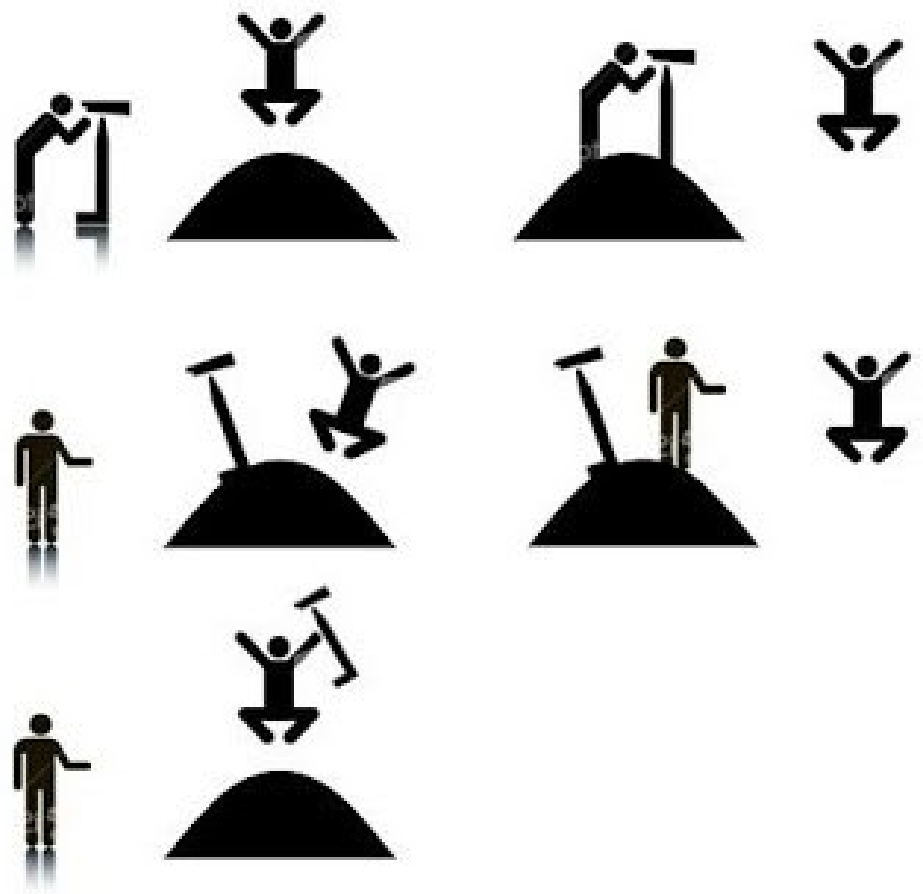

I saw the man. The man was on the hill. I was using a telescope.
I saw the man. I was on the hill. I was using a telescope.
I saw the man. The man was on the hill. The hill had a telescope.
I saw the man. I was on the hill. The hill had a telescope.
I saw the man. The man was on the hill. I saw him using a telescope.

# АОТ в индустрии

Популярные задачи: суммаризация большого колчиества документов, анализ историй болезни, анализ тональности, рекомендательные системы, веб-аналитика

- Поисковые машины: Google, Baidu, Yahoo, Yandex
- Распознавание речи: Siri, Google Now, Xbox
- Аналитика: SAS Text Miner, IBM Watson, IBM Content Analytics, OntosMiner, Intersystems iKnow, SAP HANA, Oracle Text
- Проверка правописания: Word, Pages, iOS apps, Android apps

# План

1. Введение в автоматическую обработку текстов
2. Введение в информационный поиск
3. Вероятностное тематическое моделирование
4. Классификация текстов по теме и по тональности
5. Использование методов классификации последовательностей (sequence labelling) в задачах извлечения информации
6. Кластеризация текстов
7. Методы определения семантической близости

# Сегодня

# Сколько слов в этом предложении?

"На дворе трава, на траве дрова, не руби дрова на траве двора."
12 **токенов**: На, дворе, трава, на, траве, дрова, не, руби, дрова, на, траве, двора
8 - 9 **типов**: На/на, дворе, трава, траве, дрова, не, руби, двора.
6 **лексем**: на, не, двор, трава, дрова, рубить

**Токен и тип**

Тип – уникальное слово из текста
Токен – тип и его позиция в тексте

$N$ = число токенов
$V$ – словарь (все типы)
$|V|$ = количество типов в словаре
Как связаны $N$ и $|V|$?

# Закон Ципфа

В любом достаточно большом тексте ранг типа обратно пропорционален его частоте:

$$f = \frac{a}{r}$$

$f$ – частота типа

$r$ – ранг типа

$a$ – параметр, для славянских языков – около 0.07

# Закон Ципфа: пример

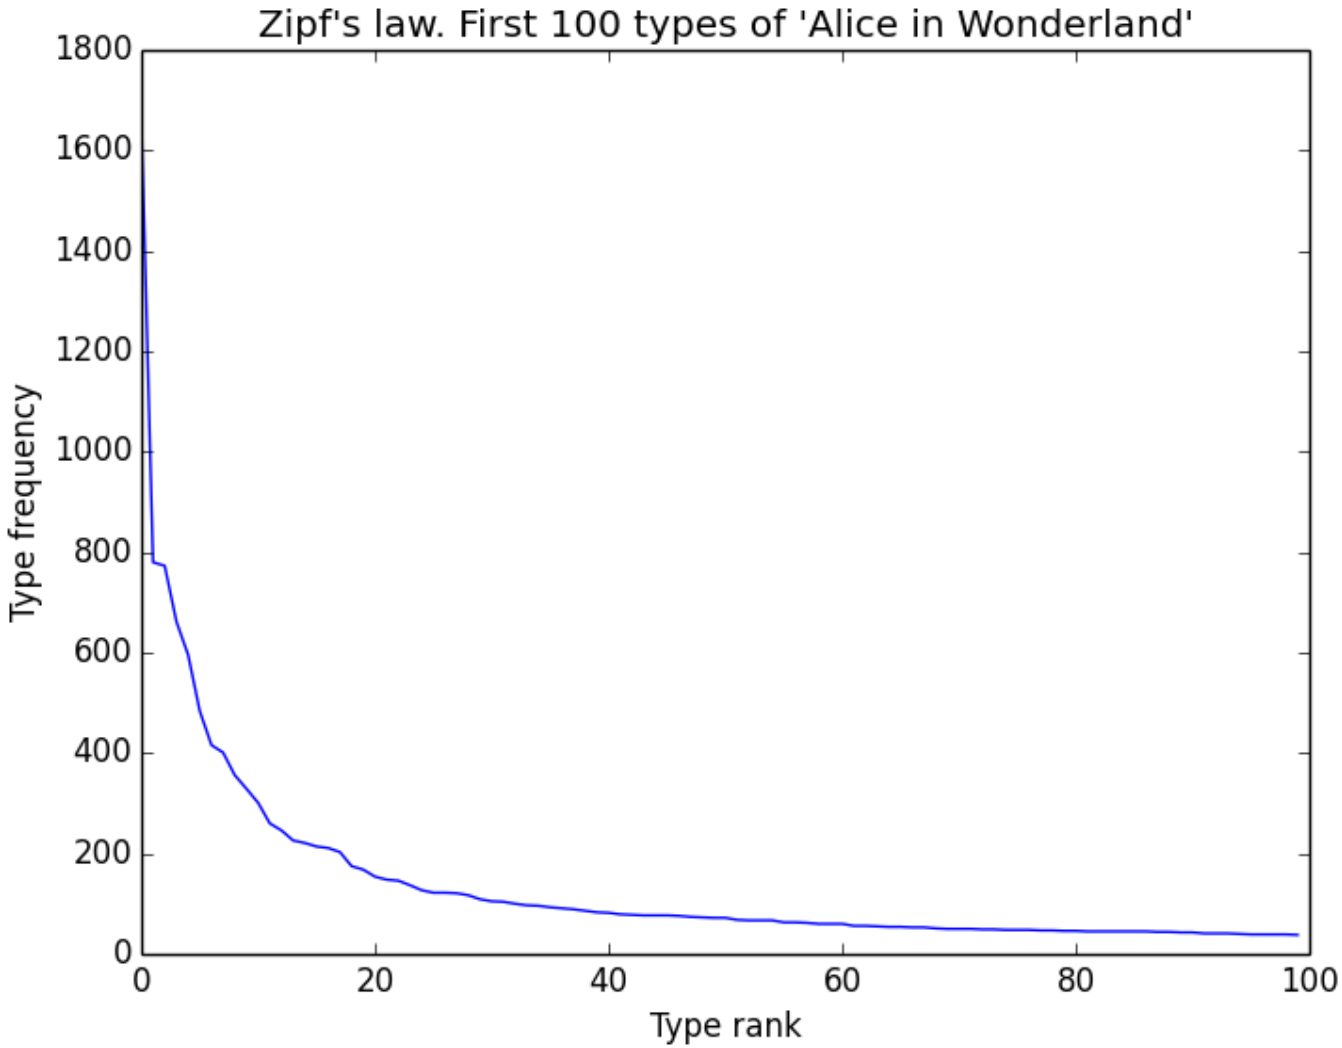

# Закон Хипса

С увеличением длины текста (количества токенов), количество типов увеличивается в соответствии с законом :

$$|V| = K * N^b$$

$N$ = число токенов
$|V|$ = количество типов в словаре
$K, b$ – параметры, обычно $K \in [10, 100], b \in [0.4, 0.6]$

# Токенизация

- Разбиение текста на отдельные слова
- Сегментация предложений

# Почему сложна токенизация?

- Простой пример: “В Нью-Йорке хороший маффин стоит 3.88$”.
  - “.” – это токен?
  - 3.88$ – это один токен или несколько?
  - Нью-Йорк – это один токен или несколько?
- В реальных данных много шума: html-разметка, ссылки, лишние знаки пунктуации.
- В реальных данных много опечаток: аптом она сказла
- Точка не всегда означает конец предложения: р. Москва, к.т.н., 20-ые гг.

# Токенизация с помощью регулярных выражений

Задаем шаблоны, описывающие токены.

## Регулярные выражения на Python

```
In[1]:  import re
In[2]:  prog = re.compile('[A-Za-z]+')
In[3]:  prog.findall("Words, words, words.")
Out[1]:  ['Words', 'words', 'words']
```

# Сегментация предложений (1)

Как определить границы предложения?

- “?”, “!” как правило, однозначны
- Точка “.” не всегда означает конец предложения
- Прямая речь: — Кто там? — спросил дядя Фёдор. — Это я!

Бинарный классификатор для сегментации предложений: для каждой точки “.” определить, является ли она концом предложения или нет.

## Бинарный классификатор

Бинарный классификатор $f : X \implies 0, 1$ получает на вход таблицу $X$ (каждая строчка – одна точка в тексте, столбцы – признаки) и решает EndOfSentence (0) или NotEndOfSentence (1).

# Сегментация предложений (2)

Какие признаки использовать для классификации?

- Количество пробелов после точки
- Заглавная или строчная буква после точки
- Принадлежит ли точка к аббревиатуре
- и т.д.

Нужно много разметки!

# Natural Language Toolkit

Natural Language Toolkit умеет все

## NLTK tokenizers

```
In[1]:  from nltk.tokenize import RegexpTokenizer,
wordpunct_tokenize
In[2]:  s = ”Good muffins cost $3.88 in New York.  \n Please
buy me two of them.  \n Thanks.”
In[3]:  tokenizer = RegexpTokenizer(’\w+| \$ [\d \.]+ | S
\+’)
In[4]:  tokenizer.tokenize(s)
Out[1]:[’Good’, ’muffins’, ’cost’, ’$3.88’, ’in’, ’New’,
’York’, ’.’, ’Please’, ’buy’, ’me’, ’two’, ’of’, ’them’,
’.’, ’Thanks’, ’.’]
In[5]:  wordpunct_tokenize(s)
Out[2]:  [’Good’, ’muffins’, ’cost’, ’$’, ’3’, ’.’, ’88’,
’in’, ’New’, ’York’, ’.’, ’Please’, ’buy’, ’me’, ’two’,
’of’, ’them’, ’.’, ’Thanks’, ’.’]
```

# Обучение токенизации

`nltk.tokenize.punkt` – это инструмент для обучения токенизации по размеченным данным. Содержит обученный токенизатор Punkt_tokenizer для текстов на английском языке.

## Punkt_tokenizer

```
In[1]:  import nltk.data
In[2]:  sent_detector =
nltk.data.load('tokenizers/punkt/english.pickle')
In[3]:  sent_detector.tokenize(s)
Out[1]:  ['Good muffins cost $3.88 in New York.', 'Please
buy me two of them.', 'Thanks.']
```

# Морфологический анализ

Задачи морфологического анализа:

- **Разбор слова** — определение нормальной формы (леммы) и грамматических характеристик слова
- **Синтез слова** — генерация слова по заданным грамматическим характеристикам

Морфологический процессор – инструмент морфологического анализа:

- Морфологический словарь
- Морфологический анализатор

# Морфологический анализ

У каждого слова есть **лемма** (нормальная форма):

- кошке, кошку, кошкам, кошкой $\Longrightarrow$ кошка
- бежал, бежит, бегу $\Longrightarrow$ бежать
- белому, белым, белыми $\Longrightarrow$ белый

## Часть речи [Manning, Schuetze, 1999]

Слова можно объединить в классы – части речи – в соответствии с их ситаксическими характеристиками. Основные части речи: существительные, предлоги и глаголы. Основные морфологические процессы: словоизменение (спряжение и склонение), словообразование (клуб – клубный), словосложение (земле+устройство).

# Парадигма

Словоизменительная парадигма — список словоформ, принадлежащих одной лексеме и имеющих разные грамматические значения.

| | | |
|---|---|---|
| пальто- | плакать | рук-а |
| | плач-у | рук-и |
| | плач-ешь | рук-е |
| | плач-ет | рук-у |
| | плач-ем | рук-ой |
| | плач-ете | о рук-е |
| | плач-ут | |

# Грамматические характеристики [Попов, 1982]

- **Существительное**: род (м.р., ж.р., с.р.), число (ед., мн.), падеж (им., род., дат., вин., твор., пред.), одушевленность (од., неод.)
- **Полное прилагательное и причастие**: пассивность (пасс., акт.), время (прош., наст.), род (м.р., ж.р., с.р.), число (ед., мн.), падеж (им., род., дат., вин., твор., пред.), одушевленность (од., неод.), вид (сов., несов.)
- **Краткое прилагательное и причастие**: пассивность (пасс., акт.), время (прош., наст.), род (м.р., ж.р., с.р.), число (ед., мн.)
- **Глагол**: пассивность (пасс., акт.), время (прош., наст.) род (м.р., ж.р., с.р.), число (ед., мн.)
- **Деепричастие**: пассивность (пасс., акт.), время (прош., наст.), число (ед., мн.)
- **Наречие**: обстоятельственное (обст.), определительное (опред.)
- **Количественное числительное**: тип “1”, “2”, “5”, дробное (дроб.), неопределенное (неопр.), именнованное (именнов.),
- **Местоимение**: класс: притяжательное (прит.), указательное (указ.), возвратное (возвр.,), возвратно-аттрибутивное (возвр.-атр.), третьего лица (3 л.); род (м.р., ж.р., с.р.), число (ед., мн.), падеж (им., род., дат., вин., твор., пред.)
- **Союз**: сочинительный (соч.), подчинительный (подч.)
- **Предлог**: падеж (род., дат., вин., твор., пред.)
- **Частица**: вопросительная (вопр.), отрицательная (отр.)

# Типы существительных [Попов, 1982]

Морфологические типы существительных

| | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Им. ед. | ∅ | ∅ | ∅ | а | я, ья | я | я | ь | ь, й | й | о | о | я | е | е, ье | е |
| Род. ед. | а | а | а | ы, и | и, ьи | и | и | и | я | я | а | а | и | а | я, ья | я |
| Дат. ед. | у | у | у | е | е, ье | е | и | и | ю | ю | у | у | и | у | ю, ью | ю |
| Вин. ед. | | | | у | ю, ью | ю | ю | ь | | | | | | | | |
| Тв. ед. | ом, ем | ом | ом | ой, ой | ей, ьей | ей | ей | ью | ем | ем | ом | ем | ем | ем | ем, ьем | ем |
| Предл. ед. | е | е | е | е | е, ье | е | и | и | е | и | е | е | и | е | е, ье | и |
| Им. мн. | ы, и, ья | ы, и | а | ы, и | и, ьи | а | и | и | и | и | а | и, ья | а | а | я, ье | я |
| Род. мн. | ов, ев, ей, ьев | ∅ | ов | ∅ | ей | й, ь, ∅ | й | ей | ей, ев | ев | ∅, ов | ∅, ов, ьев | ∅ | ∅, ев | ий, ей | й |
| Дат. мн. | ам, ьям | ам | ам | ам | ям, ьям | ям | ям | ям | ям | ям | ам | ам, ьям | ам | ам | ям, ьям | ям |
| Вин. мн. | | | | | | | | | | | | | | | | |
| Тв. мн. | ами, ьями | ами | ами | ами | ьями, ями | ями | ями | ями | ями | ями | ами | ьями, ами | ами | ами | ями, ьями | ями |
| Предл. мн. | ах, ьях | ах | ах | ах | ьях, ях | ях | ях | ях | ях | ях | ах | ах, ьях | ах | ах | ях, ьях | ях |
| Примеры | Процесс, брат | Грамм | Номер | Матрица | Ступил, статья | Идея | Линия | Мишень | Забой, уголь | Санаторий | Тело | Дерево | Время | Полотенце | Поле, устье | Влияние |

# Стемминг

Слова состоят из морфем: $word = stem + affixes$. Стемминг позволяет отбросить аффиксы. Чаще всего используется алгоритм Портера.
**1-ый вид ошибки:** белый, белка, белье $\Longrightarrow$ бел
**2-ой вид ошибки:** трудность, трудный $\Longrightarrow$ трудност, труд, кротость $\Longrightarrow$ кротост, крот
**3-ий вид ошибки:** быстрый, быстрее $\Longrightarrow$ быст, побыстрее $\Longrightarrow$ побыст
Алгоритм Портера состоит из 5 циклов комманд, на каждом цикле – операция удаления / замены суффикса. Возможны вероятностные расширения алгоритма.

# Разрешение морфологической неоднозначности

- Существительное или глагол: стали, стекло, течь, белила, падали
- Прилагательное или существительное: мороженое, простой
- Существительное или существительное: черепах

*N*-граммные морфологические анализаторы:

- unigram tagging: выбирает самый частый / вероятный разбор
- ngram tagging: анализирует контекст текущего слова – $n$ предыдущих слов (HMM, CRF, нейронные сети, нужно много данных для обучения)
- Временные затраты VS точность разбора VS количество неоднозначных слов $\Longrightarrow$ ансамбли морфологических анализаторов

# Машинное обучение для морфологического анализа

- Классификаторы в признаковых пространствах
  Деревья решений, MaxEnt, SVD
- Графические модели
  HMM, CRF
- Нейронные сети
  - Sequence labelling: Senna
  - Structure learning: SyntaxNet

# Классификация методов извлечения ключевых слов и словосочетаний

Ключевые слова и словосочетания сложно определить формально. Поскольку определений ключевых слов и словосочетаний множество, существует масса методов их извлечения:

- с учителем VS без учителя
- частотные VS по-сложнее
- из одного текста VS из коллекции текстов
- слова (униграммы) VS биграммы VS $N$-граммы
- термины VS именованные сущности VS коллокации
- последовательные слова VS с использованием окна

# Методы извлечения ключевых слов и словосочетании с учителем

Построим бинарный классификатор с целевым признаком KeyWord (1) NotKeyWord (0). Возможные признаки для классификации:

- Слово употребляется в начале предложения
- Слово написано с заглавной буквы
- Частота слова
- Слово используется в качестве названия статьи или категории в Википедии
- Слово – именованная сущность
- Слово – термин
- И т.д.

Но нужны размеченные коллекции текстов.

# Методы извлечения ключевых слов и словосочетании без учителя

- Морфологические шаблоны
- Меры ассоциации биграмм: PMI, T-Score, LLR
- Графовые методы: TextRank [Mihalcea, Tarau, 2004]
- Синтаксические шаблоны

# Меры ассоциации биграмм (1)

$w_1, w_2$ – два слова
$f(w_1), f(w_2)$ – их частоты
$f(w_1, w_2)$ – частота биграммы $w_1 w_2$
$PMI(w_1, w_2) = \log \frac{f(w_1, w_2)}{f(w_1) f(w_2)}$

## Pointwise Mutual Information [Manning, Shuetze, 1999]

$PMI(w_1, w_2)$ показывает сколько информации о появлении одного слова содержится в появлении другого слова.

# Меры ассоциации биграмм (2)

$w_1, w_2$ – два слова
$f(w_1), f(w_2)$ – их частоты
$f(w_1, w_2)$ – частота биграммы $w_1 w_2$
$N$ – число слов
$T - score(w_1, w_2) = \frac{f(w_1,w_2) - f(w_1) * f(w_2)}{f(w_1,w_2)/N}$

## T-Score [Manning, Shuetze, 1999]

$T - score(w_1, w_2)$ – это статистический $t - test$, используемый для извлечения ключевых словосочетаний. $t - test$ измеряет разницу между ожидаемым и наблюдаемым средним значением, нормированную стандартным отклонением. Считается лучшей мерой ассоциацией биграмм. Уровень значимости при анализе, как правило, не используется.

# Меры ассоциации биграмм (3)

$w_1, w_2$ – два слова
$O_{11} = f(w_1, w_2)$ – **наблюдаемая** частота биграммы $w_1 w_2$
$E_{11} = \frac{O_{11}+O_{12}}{N} \times \frac{O_{11}+O_{21}}{N} \times N$ – **ожидаемая** частота биграммы $w_1 w_2$

| | $w_2$ | not $w_2$ |
|---|---|---|
| $w_1$ | $O_{11}$ | $O_{12}$ |
| not $w_1$ | $O_{21}$ | $O_{22}$ |

$$chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}} = |i \in 1,2, j \in 1,2| =$$

$$= \frac{N(O_{11}O_{22} - O_{12}O_{21})^2}{(O_{11} + O_{12})(O_{11} + O_{21})(O_{12} + O_{22})(O_{21} + O_{22})}$$

# Меры ассоциации биграмм в NLTK

## NLTK BigramCollocationFinder

```
In[1]:  from nltk.collocations import *
In[2]:  bigram_measures =
nltk.collocations.BigramAssocMeasures()
In[3]:  finder = BigramCollocationFinder.from_words(tokens)
In[4]:  finder.apply_freq_filter(3)
In[5]:  for i in finder.nbest(bigram_measures.pmi, 20):  ...
```

Меры ассоциации биграмм в NLTK:

- `bigram_measures.pmi`
- `bigram_measures.student_t`
- `bigram_measures.chi_sq`
- `bigram_measures.likelihood_ratio`

# TextRank: использование мер центральности графов для излвечения ключевых слов и словосочетаний (1) [Mihalcea, Tarau, 2004]

1. Вершины графа: слова
2. Ребра графа могут определяться по следующим правилам:
   - Последовательные слова
   - Слова внутри левого или правого окна в $\pm$ 2-5 слов;

   Ребра могут быть взвешенные или невзвегенные, направленные или ненправленные.
3. Любая мера центральности графа используются для определения важности вершин в графе. Слова, соответствующие наиболее важным вершинам, считаются ключевыми.
4. Если две соседние вершины оказываются важными, соответствующие им слова формируют ключевое словосочетание.

`http://web.eecs.umich.edu/~mihalcea/papers/mihalcea.emnlp04.pdf`

# TextRank (2)

**Compatibility of systems of linear constraints over the set of natural numbers. Criteria of compatibility of a system of linear Diophantine equations, strict inequations, and nonstrict inequations are considered. Upper bounds for components of a minimal set of solutions and algorithms of construction of minimal generating sets of solutions for all types of systems are given. These criteria and the corresponding algorithms for constructing a minimal supporting set of solutions can be used in solving all the**

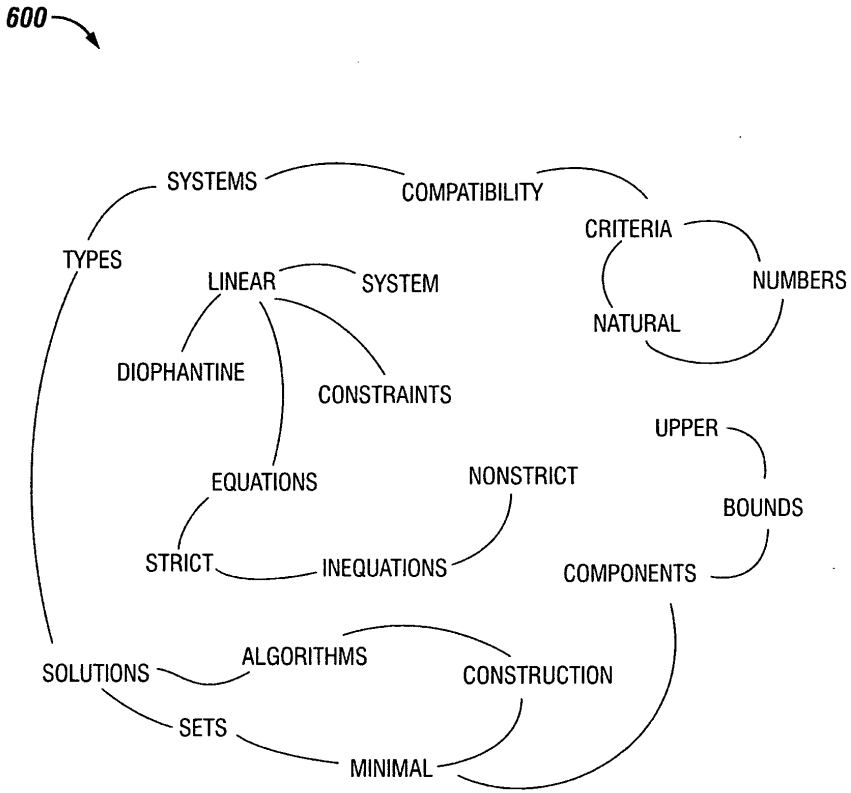


*FIG. 6*

**considered types systems and systems of mixed types.**

# TextRank (3)

$G = (V, E)$ – граф, $V$ – вершины, $E$ – ребра
$In(V_i)$ – множество исходящих ребер
$Out(V_i)$ – множество входящих ребер
Меры центральности

## PageRank [Brin, Page, 1998]

$$PR(V_i) = (1 - d) + d \times \sum_{V_j \in In(V_i)} \frac{PR(V_j)}{|Out(V_j)|}$$

## HITS [Kleinberg, 1999]

$$HITS_A(V_i) = \sum_{V_j \in In(V_i)} HITS_H(V_j)$$
$$HITS_H(V_i) = \sum_{V_j \in Out(V_i)} HITS_A(V_j)$$

# TextRank (4)

Найденные ключевые слова и словосочетания
linear constraints; linear diophantine equations; natural numbers; nonstrict inequations; strict inequations; upper bounds

# Меры контрастности для извлечения ключевых слов и словосочетаний

Рассмотрим некую коллекцию текстов. Требуется для данного текста определить слова и словосочетания, которые встречаются в нем **существенно** чаще, чем в других текстах.

## Частота терма [Luhn, 1957]

Важность терма в тексте пропорциональная его частоте.

## Обратная документная частота [Spaerck Jones, 1972]

Специфичность терма в тексте обратнопропорциональна числу текстов, в которых терм встречается.

$$tfidf(term, text, collection) = tf(term, document) \times idf(term, collection)$$

# Используемые *TF* и *IDF* веса

$tf(term, document) =$

- бинарный вес: 1, если терм встречается в тексте, 0, иначе
- частота: $f_{t,d}$
- нормированная частота: $log(1 + f_{t,d})$

$idf(term, collection) =$

- унарный вес: 1
- обратная частота: $\log \frac{N}{n_t}$, где $N$ – число текстов в коллекции, $n_t$ – число текстов, в которых встречается терм $t$
- сглаженная обратная частота: $\log \frac{N}{n_t+1}$

Самая популярная комбинация весов: $f_{t,d} \times \log \frac{N}{n_t+1}$

# Использование меры $tf - idf$ для измерения сходства текстов

Пусть каждый текст $d_i$ из коллекции текстов $D$ представлен вектором $d_i = (w_1^i, w_2^i, ..., w_{|V|}^i)$ , где $V$ – это словарь, $|V|$ – общее число термов (типов) в словаре. Получается векторное пространство размерности $|V|$, где каждое измерение задано одним термом. $w_k^i$ – это вес терма $k$ в тексте $i$ – чаше всего, вычисленный по мере $tf - idf$. Сходство между двумя текстами может быть определено как косинус между соответствующими векторами.

## Косинусная мера близости в векторной модели
## Cosine similarity in Vector Space Model (VSM) [Salton et. al, 1975]

$$cos(d_i, d_j) = \frac{d_i \times d_j}{||d_i||||d_j||} = \frac{\sum_k w_k^i \times w_k^j}{\sqrt{(\sum_k w_k^i)^2}\sqrt{(\sum_k w_k^j)^2}}$$

# Векторная модель коллекции текстов

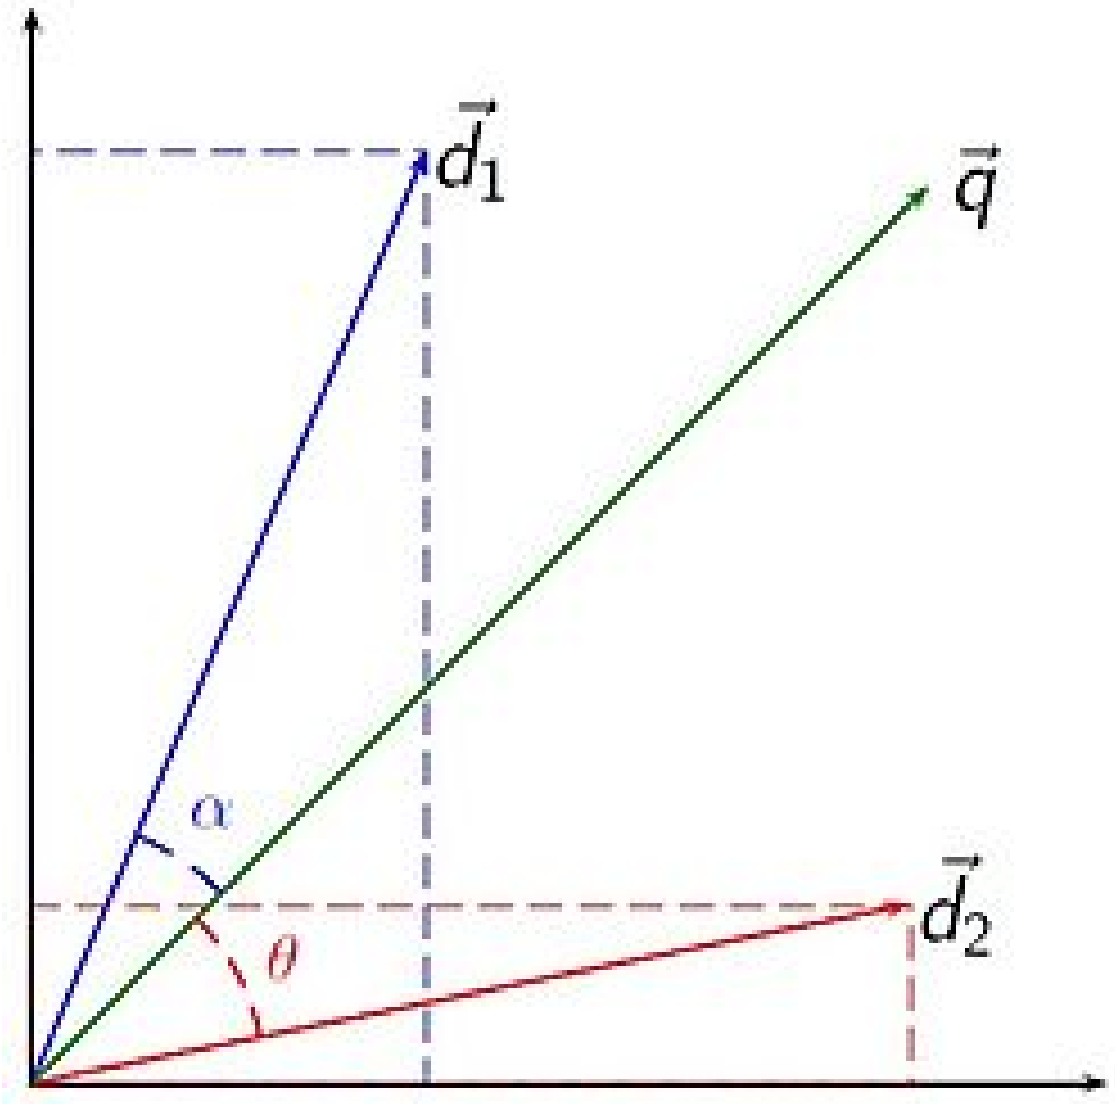

# Синтаксический анализ

- Выделение синтаксических связей между словами
- Каждое предложение представляется в виде дерева
- Выделяют деревья двух видов:
  - Деревья составляющих (constituency tree)
  - Деревья зависимостей (dependency tree)

# Генеративная модель языка

- Язык – множество цепочек слов
- Правила порождения цепочек описываются формальными грамматиками Хомского
- Грамматика: правила вида $[aAbB] \rightarrow [aBc]$, слева и справа цепочки терминальных и нетерминальных символов
- 4 вида грамматик:
  - Неограниченные грамматики
  - Контекстно-зависимые и неукорачивающие грамматики
  - Контекстно-свободные грамматики
  - Регулярные грамматики
- Для естественных языков используются контекстно-свободные грамматики вида $A \rightarrow aBa$
  - Слева – ровно один нетерминальный символ
  - Справа – произвольная цепочка
- Дерево вывода цепочки-предложения – дерево составляющих

# Пример дерева составляющих

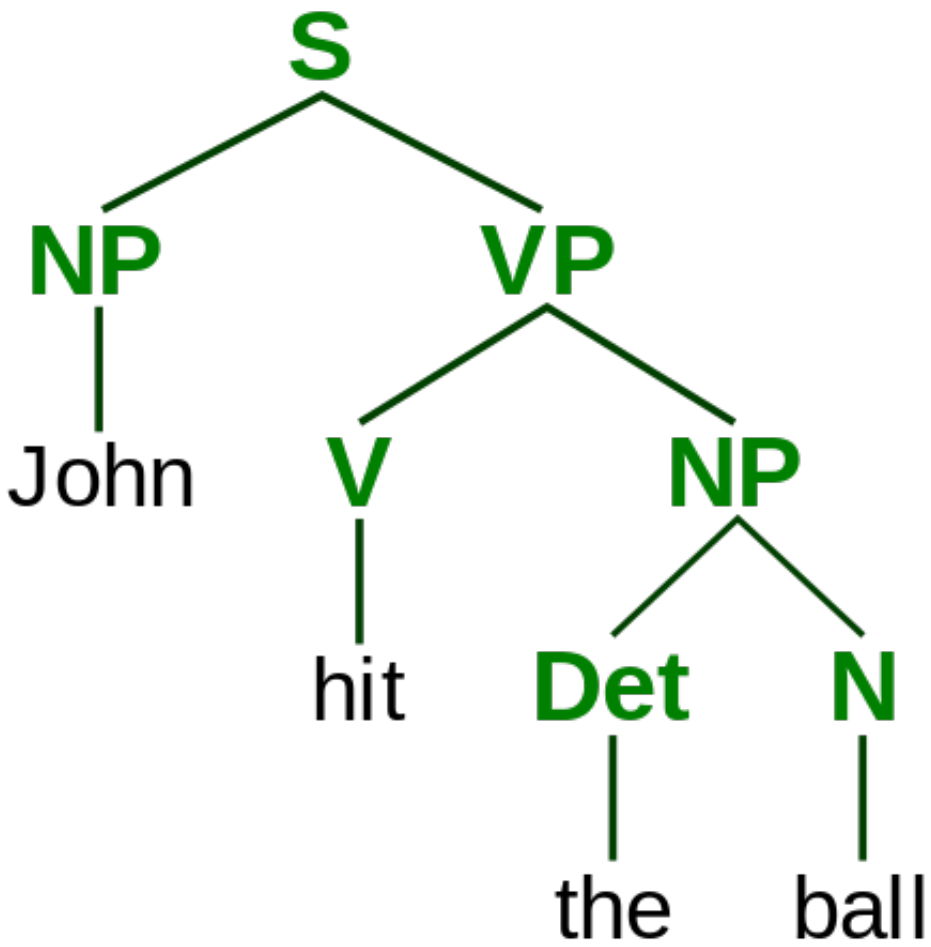


- S, NP, VP – нетерминальные символы
- V, N, Det – терминальные символы

# Пример дерева зависимостей

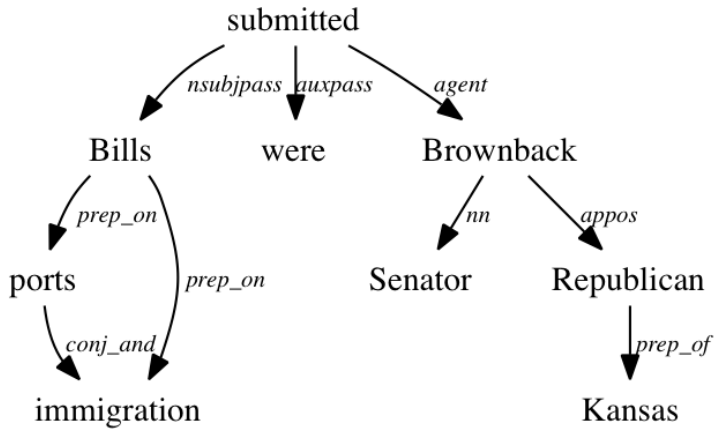


- Все слова в предложении связаны отношением типа “хозяин-слуга”, имеющим различные подтипы
- Узел дерева – слово в предложении
- Дуга дерева – отношение подчинения

# Деревья зависимостей

1. Правила (rule-based)
   - Набор шаблонов, схем, правил вывода, использующих лингвистические сведения
   - Зависит от языка
   - ЭТАП-3
2. Машинное обучение
   - Корпуса с морфологической и синтаксической разметкой
   - Не требуется знание специфики языка
   - MaltParser
3. Предложение с проективными связями может быть преобразовано в дерево составляющих

# Демо

- Berkley Tomcat constituency parser `http://tomato.banatao.berkeley.edu:8080/parser/parser.html`
- Stanford CoreNLP dependency parser `http://nlp.stanford.edu:8080/corenlp/`
- ARK dependency parser (Carnegie Melon) `http://demo.ark.cs.cmu.edu/parse`