

# Введение в анализ данных

Лекция 8

Линейная классификация

Евгений Соколов

[sokolov.evg@gmail.com](mailto:sokolov.evg@gmail.com)

НИУ ВШЭ, 2016

# Организационное

- Скоро зачёт!
- Следите за обновлениями на wiki

# План на сегодня

- Линейные модели в классификации
- Геометрия линейных моделей
- Обучение линейных классификаторов
- Логистическая регрессия
- Точность и полнота

# Модель линейной классификации

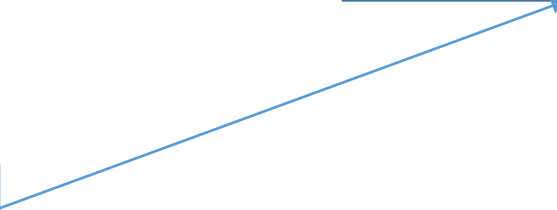
# Классификация

- $\mathbb{Y} = \{-1, +1\}$
- $-1$  — отрицательный класс
- $+1$  — положительный класс
- $a(x)$  должен возвращать одно из двух чисел

# Линейная регрессия

$$a(x) = w_0 + \sum_{j=1}^d w_j x^j$$


Вещественное  
число!



# Линейный классификатор

$$a(x) = \text{sign} \left( w_0 + \sum_{j=1}^d w_j x^j \right)$$

# Линейный классификатор






# Линейный классификатор

- Добавим единичный признак

$$a(x) = \text{sign} \sum_{j=1}^{d+1} w_j x^j = \text{sign} \langle w, x \rangle$$


# Геометрия линейного классификатора

Уравнение гиперплоскости:  $\langle w, x \rangle = 0$



# Геометрия линейного классификатора

- Линейный классификатор проводит гиперплоскость
- $\langle w, x \rangle < 0$  — объект «слева» от неё
- $\langle w, x \rangle > 0$  — объект «справа» от неё




# Геометрия линейного классификатора

- Расстояние от точки до гиперплоскости  $\langle w, x \rangle = 0$ :


$$\frac{|\langle w, x \rangle|}{\|w\|}$$

- Чем больше  $\langle w, x \rangle$ , тем дальше объект от разделяющей гиперплоскости

# Геометрия линейного классификатора




# Геометрия линейного классификатора



# Отступ

- $M_i = y_i \langle w, x_i \rangle$
- $M_i > 0$  — классификатор дает верный ответ
- $M_i < 0$  — классификатор ошибается
- Чем дальше отступ от нуля, тем больше уверенности



# Линейный классификатор

- Линейный классификатор разделяет два класса гиперплоскостью
- Чем больше отступ по модулю, тем дальше объект от гиперплоскости
- Знак отступа говорит о корректности предсказания



Функционал ошибки для  
классификации

# Линейная регрессия

- Квадратичное отклонение:

$$L(a, y) = (a - y)^2$$

- Абсолютное отклонение:

$$L(a, y) = |a - y|$$

# Линейная классификация

- Доля **неправильных** ответов:

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) \neq y_i]$$

# Линейная классификация

$a(x)$	$y$
-1	-1
+1	+1
-1	-1
<b>+1</b>	<b>-1</b>
+1	+1

- Доля неправильных ответов:

$$\frac{1}{5} = 0.2$$

# Линейная классификация

- Доля **правильных** ответов:

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) = y_i]$$

- На английском: **accuracy**

# Линейная классификация

- Доля **правильных** ответов:

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) = y_i]$$


- На английском: **accuracy**
- ВАЖНО: не переводите это как «точность»!

# Линейная классификация

- Доля неправильных ответов (через отступ):

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [y_i \underbrace{\langle w, x_i \rangle}_{M_i} < 0]$$

# Пороговая функция потерь





# Линейная классификация

- Доля неправильных ответов:

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \underbrace{[y_i \langle w, x_i \rangle < 0]}_{M_i}$$


- Разрывная функция
- Непонятно, как оптимизировать

# Оценка функции потерь

- Возьмем любую гладкую оценку пороговой функции:

$$[M < 0] \leq \tilde{L}(M) = \tilde{L}(y\langle w, x \rangle)$$

# Примеры оценок



# Примеры оценок

- $\tilde{L}(M) = \log_2(1 + \exp(-M))$  — логистическая
- $\tilde{L}(M) = \exp(-M)$  — экспоненциальная
- $\tilde{L}(M) = \max(0, 1 - M)$  — кусочно-линейная

# Оценка функции потерь

- Возьмем любую гладкую оценку пороговой функции:

$$[M < 0] \leq \tilde{L}(M)$$

- Оценим через нее функционал ошибки:

$$Q(a, X) \leq \tilde{Q}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \tilde{L}(M_i)$$

# Оценка функции потерь


$$\frac{1}{\ell} \sum_{i=1}^{\ell} [M_i < 0] \leq \frac{1}{\ell} \sum_{i=1}^{\ell} \tilde{L}(M_i) \rightarrow \min_a$$

Минимизируем  
верхнюю оценку

Надеемся, что доля  
ошибок тоже  
уменьшится

# Примеры оценок

- $\tilde{L}(a, y) = \ln(1 + \exp(-ya))$  — логистическая



# Логистическая функция потерь

$$\tilde{Q}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \log_2(1 + \exp(-y_i \langle w, x_i \rangle))$$

1. Выписали индикатор ошибки через отступ
2. Заменяли пороговую функцию потерь на гладкую функцию



# Обучение

- Обучение — с помощью любых методов оптимизации
- Например, градиентный спуск
- Борьба с переобучением: регуляризация (так же, как в линейной регрессии)

# Логистическая регрессия

# Логистическая регрессия

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \log_2(1 + \exp(-y_i \langle w, x_i \rangle)) \rightarrow \min_w$$

# Оценивание вероятностей

- $P(y = 1 \mid x) = \pi(x)$

# Оценивание вероятностей

- Кредитный скоринг
- Стратегия: выдавать кредит только клиентам с  $\pi(x) > 0.9$
- 10% невозвращённых кредитов — нормально

# Оценивание вероятностей


- Баннерная реклама
- $\pi(x)$  — вероятность, что пользователь кликнет по рекламе
- $c(x)$  — прибыль в случае клика
- $\pi(x)c(x)$  — хотим оптимизировать

# Оценивание вероятностей

- $P(y = 1 \mid x) = \pi(x)$
- $\pi(x)$  — вещественное число
- Классификатор не подходит

# Регрессия?


- $\pi(x) \approx \langle w, x \rangle = w_1 x + w_0$





# Регрессия?

- $\pi(x) \approx \langle w, x \rangle = w_1 x + w_0$



Отрицательная вероятность 0\_0


# Регрессия?

$$\pi(x) \approx \sigma(\langle w, x \rangle) = \frac{1}{1 + \exp(-\langle w, x \rangle)}$$




Сигмоида

# Сигмоида



# Логистическая регрессия

- $\pi(x) \approx \sigma(\langle w, x \rangle)$



# Логистическая регрессия

- Как оптимизировать?
- Если  $y_i = +1$ , то  $\langle w, x_i \rangle \rightarrow +\infty$
- Если  $y_i = -1$ , то  $\langle w, x_i \rangle \rightarrow -\infty$

# Логистическая регрессия

- Как оптимизировать?
- Если  $y_i = +1$ , то  $\sigma(\langle w, x_i \rangle) \rightarrow 1$
- Если  $y_i = -1$ , то  $\sigma(\langle w, x_i \rangle) \rightarrow 0$

# Логистическая регрессия

- Как оптимизировать?
- Если  $y_i = +1$ , то  $\sigma(\langle w, x_i \rangle) \rightarrow 1$
- Если  $y_i = -1$ , то  $\sigma(\langle w, x_i \rangle) \rightarrow 0$

$$\sum_{i=1}^{\ell} \{ [y_i = 1] \sigma(\langle w, x_i \rangle) + [y_i = -1] (1 - \sigma(\langle w, x_i \rangle)) \} \rightarrow \max_w$$

# Логистическая регрессия

- Как оптимизировать?
- Если  $y_i = +1$ , то  $\sigma(\langle w, x_i \rangle) \rightarrow 1$
- Если  $y_i = -1$ , то  $\sigma(\langle w, x_i \rangle) \rightarrow 0$

$$\sum_{i=1}^{\ell} \{ [y_i = 1] \sigma(\langle w, x_i \rangle) + [y_i = -1] (1 - \sigma(\langle w, x_i \rangle)) \} \rightarrow \max_w$$

- Слишком слабый штраф
- Если  $y_i = +1$  и  $\sigma(\langle w, x_i \rangle) = 0$ , то штраф = 1



# Логистическая регрессия


- Как оптимизировать?
- Если  $y_i = +1$ , то  $\sigma(\langle w, x_i \rangle) \rightarrow 1$
- Если  $y_i = -1$ , то  $\sigma(\langle w, x_i \rangle) \rightarrow 0$

$$\sum_{i=1}^{\ell} \{ [y_i = 1] \log_2 \sigma(\langle w, x_i \rangle) + [y_i = -1] \log_2 (1 - \sigma(\langle w, x_i \rangle)) \} \rightarrow \max_w$$

- Если  $y_i = +1$  и  $\sigma(\langle w, x_i \rangle) = 0$ , то штраф  $= -\infty$



# Логистическая регрессия



# Логистическая регрессия

- Если вспомнить арифметику, то получим эквивалентную задачу:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \log_2(1 + \exp(-y_i \langle w, x_i \rangle)) \rightarrow \min_w$$

# Логистическая регрессия

- Линейная модель классификации:  $a(x) = \text{sign } \langle w, x \rangle$
- Позволяет оценивать вероятности:  $\pi(x) = \sigma(\langle w, x \rangle)$
- Обучение: градиентный спуск

# Метрики качества классификации

# Качество классификации

- Доля неправильных ответов:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) \neq y_i]$$

# Качество классификации

- Доля правильных ответов (accuracy):

$$\frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) = y_i]$$

# Несбалансированные выборки

- Пример:
  - Класс -1: 950 объектов
  - Класс +1: 50 объектов
- $a(x) = -1$
- Доля правильных ответов: 0.95



# Несбалансированные выборки

- $q_0$  — доля объектов самого крупного класса
- Для разумных алгоритмов:

$$\text{accuracy} \in [q_0, 1]$$

- Если получили большой accuracy — посмотрите на баланс классов

# Цены ошибок

- Пример: кредитный скоринг
- Модель 1:
  - 80 кредитов вернули
  - 20 кредитов не вернули
- Модель 2:
  - 48 кредитов вернули
  - 2 кредита не вернули
- Кто лучше?

# Цены ошибок

- Что хуже?
  - Выдать кредит «плохому» клиенту
  - Не выдать кредит «хорошему» клиенту
- Доля верных ответов не учитывает цены ошибок

# Матрица ошибок

	$y = 1$	$y = -1$
$a(x) = 1$	True Positive (TP)	False Positive (FP)
$a(x) = -1$	False Negative (FN)	True Negative (TN)

# Матрица ошибок

- Модель  $a_1(x)$ :

	$y = 1$	$y = -1$
$a(x) = 1$	80	20
$a(x) = -1$	20	80

- Модель  $a_2(x)$ :

	$y = 1$	$y = -1$
$a(x) = 1$	48	2
$a(x) = -1$	52	98

# Точность (precision)

- Можно ли доверять классификатору при  $a(x) = 1$ ?

$$\text{precision}(a, X) = \frac{TP}{TP + FP}$$

# Точность (precision)

- Модель  $a_1(x)$ :

	$y = 1$	$y = -1$
$a(x) = 1$	80	20
$a(x) = -1$	20	80

- $\text{precision}(a_1, X) = 0.8$

- Модель  $a_2(x)$ :

	$y = 1$	$y = -1$
$a(x) = 1$	48	2
$a(x) = -1$	52	98

- $\text{precision}(a_2, X) = 0.96$

# Полнота (recall)

- Как много положительных объектов находит классификатор?

$$\text{recall}(a, X) = \frac{TP}{TP + FN}$$



# Полнота (recall)

- Модель  $a_1(x)$ :

	$y = 1$	$y = -1$
$a(x) = 1$	80	20
$a(x) = -1$	20	80

- $\text{recall}(a_1, X) = 0.8$

- Модель  $a_2(x)$ :

	$y = 1$	$y = -1$
$a(x) = 1$	48	2
$a(x) = -1$	52	98

- $\text{recall}(a_2, X) = 0.48$

# Кредитный скоринг

- Неудачных кредитов должно быть не больше 5%
- Ограничение:  $\text{precision}(a, X) \geq 0.95$
- Максимизируем полноту

# Медицинская диагностика

- Надо найти не менее 80% больных
- Ограничение:  $\text{recall}(a, X) \geq 0.8$
- Максимизируем точность

# Несбалансированные выборки

- $\text{accuracy}(a, X) = 0.99$
- $\text{precision}(a, X) = 0.33$
- $\text{recall}(a, X) = 0.1$

	$y = 1$	$y = -1$
$a(x) = 1$	10	20
$a(x) = -1$	90	10000

# Резюме

- Линейные классификаторы разделяют классы гиперплоскостью
- Логистическая регрессия — классификация и оценка вероятности
- Качество классификации: доля правильных ответов, точность и полнота

# На следующей лекции

- Оценивание качества и подбор гиперпараметров
- Кросс-валидация
- Подробнее про точность и полноту
- Качество оценок вероятности: площади под кривыми